

albertitos_plan — trace-it

MAISA track · 500 Sombras de Alberto (ETSIT UPM, 18-20 sep 2026). trace-it es un sistema de decisiones configurable: la norma de Alberto, en lenguaje natural, se compila a código verificado y un motor determinista decide cada factura como `PAGAR`, `NO_PAGAR` o `ESCALAR`, con su evidencia.

- **Ningún LLM decide una factura.** Los agentes sólo convierten la norma en reglas (cuando la norma cambia) y explican casos escalados. Decidir cuesta **0 tokens**, y la decisión se puede repetir y auditar.
- **De la norma original (las 6 frases de `Norma_Pagos_v3`) a las decisiones: 471/471** facturas con texto iguales a nuestra referencia del lote 1, en **3 de 3 ejecuciones**, sin ninguna regla escrita a mano.
- **Lote 1 entregado: 500/500 archivos, 443 PAGAR / 36 NO_PAGAR / 21 ESCALAR**, con las reglas congeladas y la referencia en **471/471**. Los 29 escaneos pasan por OCR: 10 PAGAR y 19 ESCALAR por dato ausente, sin confirmar o que no cuadra (ADR 0025).
- **Todo paso deja un span** en nuestra base de datos (la auditoría, con el prompt exacto de cada llamada al modelo) y el mismo span va a OpenTelemetry.
- **Si cae el proveedor LLM**, cada agente pasa al siguiente modelo de su cadena; si caen todos, falla cerrado: ninguna regla cambia y ninguna decisión es incorrecta.


1. Arquitectura

1.1 Problema, usuario y formato

Alberto (el *manager*) decide hoy a mano qué facturas pagar, cruzando PDFs, un Excel caótico y un ERP de 2009, con una norma que cambia (v4 el sábado, un dato el domingo). Necesita tres cosas: decisiones que no fallen en silencio, la razón de cada una y cambiar la norma sin programar.

Formato: un backend (FastAPI + PostgreSQL, API REST y una consola web para el manager; Makefile para operar lotes). No es un chat ni un agente que decide: el filtro es binario y cada decisión tiene que poder repetirse en una auditoría. El dominio vive en un *process pack* declarativo (`processes/invoice-payment.json`: tipos de decisión con prioridad, símbolos, reglas, conectores; ADR 0007). Un segundo pack (`travel-expenses`) carga con el mismo código: la factura es configuración.

1.2 Componentes y flujo



Hay **dos tiempos**. En el *cambio de norma* trabajan los agentes, se gastan tokens y se tarda alrededor de 1,5 minutos. En la *decisión* sólo corre código: milisegundos y 0 tokens. Lo que produce un LLM y alimenta al motor (código de reglas, símbolos) se calcula una vez, se guarda y se reutiliza.

Componente	Qué hace	Estado que deja
Ingesta (features/ingestion)	Texto nativo del PDF; OCR y visión para escaneos; Excel sin ejecutar fórmulas	files por SHA-256 (inmutables); instancias PENDING con símbolos {value, origin}
Conector ERP (sources/http_connector.py)	Login y renovación del token, backoff con jitter ante 0RA-00600 , Retry-After , limitador por debajo de 10 req/s, validación del XML latin-1, descarga paginada completa	Snapshot versionado de la fuente erp (fecha y hash) + diff con el anterior
Normalizador (agente)	Cada frase de la norma es una norm rule del cliente; la parte en checks atómicos, con cita, interpretación y tipo (violation / doubt)	norm_rules ; reglas en compiling
Tester ciego + coder (agentes)	Tests desde el texto; evaluate(instance, sources, others) -> {fires, reason} hasta pasarlos; impact check contra el histórico	Regla active , draft o blocked , con report (tests, intentos, disputas, activación)
Sandbox (agents/sandbox.py)	Allowlist AST, builtins restringidos, subprocesso python -I -S -B con timeout y rlimits; un subprocesso por regla sobre todo el lote	Nada: función pura
Motor (decisions/engine.py)	Ejecuta todas las reglas activas; combina por prioridad ESCALAR > NO_PAGAR > PAGAR	Fila de decisión append-only con el resultado de cada regla y el hash del conjunto de reglas
Export	La última decisión del motor, una línea por archivo; 409 mientras algo esté PENDING	outcomes.jsonl
Traza (core/events.py)	Spans jerárquicos; API /traces , /instances/{id}/trace , /rules/{id}/trace , /processes/{id}/metrics ; espejo OTel	Tabla events

Reprocesado. Una actualización del ERP o un dato corregido crea un snapshot nuevo; POST /processes/{id}/reprocess?dry_run=true enseña qué cambiaría y la ejecución real añade una decisión sólo donde cambia. Una instancia que decidió una persona no se toca: sale como conflicto. Ensayado con una actualización simulada del ERP (dos filas): diff added 1, changed 1, 499 sin cambio y 1 cambio (2026-01-12_P010.pdf PAGAR → NO_PAGAR , pedido ya pagado).

1.3 Reparto entre agentes, modelos y personas

Actor	Hace	Nunca hace
Normalizador (LLM)	Norma → checks; marca explicit/policy y violation/doubt con la cita	Decidir una factura
Tester (LLM)	≥6 tests desde el texto de la regla; arbitra disputas releendo el texto	Ver el código
Coder (LLM)	Escribe evaluate , hasta 4 intentos contra los tests; puede disputar un test citando la regla o responder NeedsData	Inventar un campo; devolver la decisión (sólo fires y reason)
Asistente (LLM)	Explica un caso escalado y propone decisión y regla (~3,7k tokens)	Cambiar el resultado exportado
Motor + sandbox (código)	Decide todas las instancias	Llamar a un LLM, leer el reloj o la red
Manager (persona)	Pega la norma; resuelve la cola ESCALAR ; lee los findings del histórico; activa o revierte configuraciones	Editar la historia: su resolución es una fila nueva

Modelos. Todos los roles usan Helmlcode deepseek-v4-flash , con reserva glm5.3 → qwen3.6 (el tester en orden inverso). La configuración va por caso de uso y rol, en versiones append-only (ADR 0011): modelo, reservas, timeout, max_tokens , guía del dominio y ejemplos. Cada llamada guarda config_id y prompt_hash , así que dos configuraciones se comparan con datos.

1.4 Cómo se observan y se recuperan los fallos

Seguir una decisión. GET /instances/{id}/trace da el archivo (hash), lo que leyó la ingesta y el origen de cada símbolo, el snapshot de fuentes usado, la respuesta de cada regla (con su texto y la frase de la norma de la que

viene), la razón (el código de la regla, p. ej. `IMPOSSIBLE_DATE 2026-02-31`), las resoluciones y el export. De ahí, `GET /rules/{id}/trace`: frase de la norma → llamada al normalizador → tests → intentos del coder → *impact check* → activación, **con el prompt exacto que vio cada modelo** y su respuesta.

Señales para Alberto (`GET /processes/{id}/metrics`): ejecuciones e instancias/s, p50/p95 por paso, llamadas LLM con reintentos, errores y tokens por modelo y rol, decisiones por resultado, escaladas por causa (`MISSING_DATA`, `RULE_ERROR`, `RULE_NEEDS_DATA`, `RULE_CONFLICT`) y pendientes.

Fallo	Qué pasa	Qué se conserva
Proveedor LLM caído, 5xx, 429 o timeout	Siguiente modelo de la cadena; el span guarda <code>chain</code> , <code>failed_attempts</code> y el modelo que respondió. <code>make demo-llm-down: deepseek-v4-flash</code> inalcanzable → responde <code>glm5.3</code>	Todo
Respuesta cortada (<code>finish_reason = length</code>)	Cuenta como fallo del proveedor: siguiente modelo	Todo
Respuesta inválida	El validador devuelve <code>ModelRetry</code> con el error; reintentos acotados; no cambia de modelo	Todo
Todos los modelos fallan	502; la regla nueva queda <code>draft</code> con el error y no se puede publicar: la versión publicada sigue decidiendo con sus reglas completas	Reglas y decisiones
La regla falla al ejecutarse	ESCALAR con <code>RULE_ERROR <id>: ...</code> ; nunca cuenta como "no disparó"	La razón exacta
Falta un dato obligatorio	ESCALAR con <code>MISSING_DATA: <símbolos></code>	—
Escaneo con un dato sin confirmar, o que las reglas rechazarían	ESCALAR con <code>UNVERIFIED_DATA</code> o <code>SCAN_REVIEW: <regla></code> : una mala lectura no se paga ni se rechaza (ADR 0025)	La lectura OCR
El ERP cambia después de decidir	Repetición en seco; cada decisión que cambiaría es una alerta para el manager (ADR 0026)	La decisión original
ERP: <code>ORA-00600</code> , 429, token caducado, XML inválido	Backoff, <code>Retry-After</code> , renovación y validación; si la sync falla, sigue vigente el snapshot anterior	Snapshot anterior
Se lanza un run con reglas compilando	409: nunca se decide con la norma a medias	—
Reinicio a mitad de compilación	Al arrancar se reencolan las reglas en <code>compiling</code> (best effort; si no, <code>POST /rules/{id}/compile</code>)	Reglas en BD
Duplicados	Archivo = hash de su contenido; una línea por nombre; <code>reprocess</code> sólo añade donde cambia	—
Base de datos	<code>make backup</code> (<code>pg_dump</code> , 0,5 s) y restauración en una BD nueva (0,3 s)	Dump

1.5 Escala y coste, medidos

Condiciones: MacBook Apple M4 Pro (14 núcleos, 24 GB), CPython 3.12, PostgreSQL 16 en Docker, el ERP del reto con su latencia y sus fallos, Helmcode con concurrencia 5; medido el 19-sep-2026 (`docs/scale-and-cost.md`; los tiempos salen de nuestros propios spans).

Qué	Medida	Cómo
Motor, 11 reglas generadas desde la norma	899 facturas/s (500 en 556 ms)	Mediana de 3 reprocesados <i>dry-run</i>
Motor, 16 reglas escritas a mano	588 facturas/s (851 ms)	Ídem; cada regla p50 38 ms, p95 91 ms
Tokens por decisión	0	No hay LLM en el camino de decisión
Norma → reglas activas	85–103 s (11 reglas, 5 compilaciones en paralelo)	Dos ejecuciones integradas
Tokens por regla / por norma completa	~12,4k / ~149k (106,1k entrada + 42,4k salida, 24 llamadas)	<code>GET /processes/1/metrics</code>
Tokens por sugerencia del asistente	~3,7k	3 casos
Ingesta por la API de subida, con OCR	PDF con texto 25 ms ; escaneo 1,2 s (mediana); 500 archivos en 74,4 s, pico 2,6 GB	Un cliente, caché en frío, OCR local
Lote 1 entregado	500/500 exportados: 443 / 36 / 21 ; subidas con OCR, sync del ERP y motor en 353 s	<code>make check-outcomes</code> , referencia 471/471

Qué	Medida	Cómo
Sync del ERP	516 filas, 26 páginas, 5,4 s (mediana de 3), 2-3 0RA-00600 reintentados, 1 login	Span sync_source
Calidad desde la norma original	471/471 en 3 de 3 ejecuciones (0,9, 2,0 y 2,3 min)	make eval-norm contra nuestra referencia

Coste. El volumen de facturas no entra en la fórmula: 500 o 500.000 facturas cuestan lo mismo.

```
tokens/mes ≈ normas_cambiadas × (6,2k + reglas × (5,0k + 7,4k × intentos))
+ escaladas_consultadas × 3,7k
```

Ejemplo con volúmenes supuestos (no medidos): 10.000 facturas/mes, dos normas de 11 reglas y el asistente abierto en cada escalada (6,2 %, 620 casos): ≈ 2,6M tokens/mes, el 88 % del asistente opcional. Helmcode es tarifa plana. Con precios públicos de Claude Opus 5 (5 \$/25 \$ por millón), una norma entera cuesta ~1,59 \$ y el mes del ejemplo ~30 \$. El motor cuesta 0 \$ en cualquier caso.

Evolución ante nuevos inputs.


Nuevo input	Qué cambia
PDFs escaneados	Configuración: descargar los pesos OCR (o clave de un VLM). El camino OCR ya existe
Otra hoja de cálculo	Configuración: mapear columnas a los nombres que usan las reglas; código sólo si el formato es nuevo
Emails	Un conector pequeño (.eml → adjuntos al camino PDF) y quizá símbolos nuevos; motor y reglas igual
Otro ERP o API	Su entrada en sources.json ; código sólo para JSON u OAuth
Norma nueva	Nada: POST /processes/{id}/norm ; ~12,4k tokens y ~11 s por regla, comprobada contra el histórico
Otro caso de uso	Un pack y su use-case.json ; 0 líneas de código (ADR 0007, 0011)

Límites que conocemos.

- **El normalizador varía entre ejecuciones** con temperature = 0 : un check salió explicit en dos ejecuciones y policy en otra, con la misma decisión. Para la entrega generamos las reglas, las comprobamos contra la referencia y las congelamos.
- **El OCR es el cuello de botella:** los escaneos son el 6 % del lote 1 y el 76 % del tiempo de ingesta. En el lote entregado, 6 llamadas a Gemini fallaron (ProviderUnavailable) en 3 escaneos, que quedaron en ESCALAR (MISSING_DATA).
- **La regla de pedido duplicado es cuadrática:** con 8.000 facturas en un proceso tarda 9,4 s de su límite de 10 s (medido). Entonces falla cerrada (RULE_ERROR → ESCALAR). Arreglo simulado: indexar others por pedido, 50.000 en 31 s.
- **Un solo proceso API:** las compilaciones corren en su event loop, y las reglas se ejecutan una tras otra en un núcleo de 14. Repartirlas en un pool dividiría el tiempo del motor.
- **El sandbox aísla a nivel de Python,** sin namespaces de red ni de disco. Es aceptable para código que escriben nuestros compiladores; el siguiente paso sería un contenedor con network_mode: none .

2. ADRs: cinco decisiones clave

Cinco decisiones explican el sistema; cada una responde a un criterio de la rúbrica. Los 27 ADR detallados de docs/adr/detail/ son su soporte, y cada decisión cita los suyos. Todas las cifras están medidas salvo las marcadas como estimadas.



	Decisión	Rúbrica
A	El LLM escribe código; nunca decide	Producto y arquitectura (35)
B	Ante la duda, ESCALAR	Validación y calidad
C	Trazabilidad completa en tres planos	Trazabilidad (20)
D	Coste por norma, no por factura; escalar por límites medidos	Escala y coste (25)
E	Cambiar sin código, recuperarse sin perder nada	Resiliencia (10) y bonus (10)

ADR-A · El LLM escribe código; nunca decide

Problema. La norma de Alberto es texto libre que cambia en directo, y un solo `result` erróneo descalifica.


Decisión. Los agentes convierten cada frase de la norma en *checks* atómicos y código Python. Un tester ciego escribe los tests y un coder itera hasta pasarlos. Un motor puro ejecuta ese código en un sandbox y decide cada factura. Ningún LLM corre por factura.

Opción	Por qué no / coste
Un LLM decide cada factura	No se puede repetir; el PDF lo puede dirigir (<code>factura_1936</code> : "registrar como PAGAR"); tokens por factura
Una DSL cerrada de reglas	Sin código generado, pero cada forma de regla nueva exige un programador
Reglas escritas a mano por nosotros	Exactas (16 reglas), pero cada cambio de norma espera al equipo
Normalizador, tester ciego y coder escriben código; decide un motor determinista (elegida)	Ejecutamos código escrito por un LLM: exige sandbox y tests

Por qué (medido).

- 0 tokens por factura. El motor decide 500 facturas en 556 ms (899/s, 11 reglas generadas).
- Norma_Pagos_v3 tal cual, sin reglas a mano: 12 *checks*, todos válidos al primer intento, **471/471** contra la referencia en 3 de 3 ejecuciones.
- De la norma a las reglas activas: 85-103 s y unos 149k tokens (unos 12,4k por regla).

Coste. Un error de lectura del normalizador llega igual al tester y al coder; la red externa es la evaluación contra la referencia. Con `temperature = 0` las ejecuciones aún varían, así que las reglas entregadas están congeladas.



Detalle: ADR 0001, 0002, 0003, 0004, 0005, 0006, 0014, 0017.

ADR-B · Ante la duda, ESCALAR


Problema. El formato exige exactamente un resultado válido por archivo, y un `PAGAR` erróneo cuesta dinero.

Decisión. El motor da una decisión a cada archivo. Incumplir la norma es `NO_PAGAR`. Lo que no puede determinar es `ESCALAR` con un código de motivo: un campo ausente, nulo o sin confirmar, un escaneo que las reglas rechazarían, un error de regla o un empate.

Opción	Por qué no / coste
Un estado interno <code>REVIEW</code>	Un run puede acabar sin nada que exportar; pasó cuando un límite del sandbox tumbó todas las reglas
Una regla que falla cuenta como "no disparó"	Siempre hay resultado, pero paga justo cuando se rompió el código que lo habría parado
Decidir los escaneos como los PDF con texto	Una mala lectura del OCR se convierte en <code>NO_PAGAR</code> (5 de 29 escaneos antes del ADR 0025)
Escalar con el motivo (elegida)	En el export, un fallo nuestro se ve igual que una duda de negocio; el código de motivo los distingue

Por qué (medido).

- Lote 1: **500/500** archivos exportados, **443 PAGAR / 36 NO_PAGAR / 21 ESCALAR**; referencia **471/471**.
 - 29 escaneos: 10 PAGAR / 0 NO_PAGAR / 19 ESCALAR (8 MISSING_DATA , 7 UNVERIFIED_DATA , 4 SCAN_REVIEW).
 - 50.000 facturas, todas las reglas agotan su tiempo: 47.100 ESCALAR con RULE_ERROR , ninguna pagada por error.
- Coste.** Una persona revisa 21 de 500 archivos (4,2 %), algunos por fallos nuestros.



Detalle: ADR 0016, 0025, 0009, 0010, 0021. Una regla que no compiló nunca decide: no se puede publicar (ADR-E).

ADR-C · Trazabilidad completa en tres planos

Problema. Cualquiera tiene que poder seguir una factura desde su PDF hasta la línea exportada, y una regla desde su frase de la norma hasta su código, incluido lo que vio cada modelo.

Decisión. Cada paso escribe un span en nuestra tabla `events` de Postgres, la fuente de verdad de la auditoría, enlazada con facturas, reglas y versiones del proceso. Los mismos spans van a OpenTelemetry, agrupados en tres planos: ingesta, agentes y ejecución.


Opción	Por qué no / coste
Sólo Logfire u otro backend OTel	Buena interfaz, pero la auditoría queda en un tercero y no se cruza con decisiones y reglas
Langfuse, autoalojado o en la nube	Postgres, ClickHouse, Redis y S3 para un MVP, y sólo cubre el plano LLM. Aplazado
Logs planos	Sin árbol, sin cruce con decisiones, sin métricas
Spans propios en Postgres, replicados a OTel (elegida)	Dos escrituras por span; los prompts se guardan enteros

Por qué (medido).

- Ejecución de cobertura: 315 spans en 59 trazas, un span por cada punto de entrada; el stream en directo envió 121 eventos, cada uno con su plano.
- Cada `llm_run` guarda instrucciones, prompt, respuesta, tokens, `config_id` y `prompt_hash`: 4,9-8,6 kB por fila.
- Unos 7 spans por factura, de 571-954 B cada uno.

Coste. Postgres crece unos 25 kB por factura. Si el proceso muere a mitad de una traza, se pierden los spans aún sin escribir.

Seguir una decisión: `GET /instances/{id}/trace`, o `make trace-decision FILE=scan_002.pdf`.



Detalle: ADR 0018, 0022 (evidencia OCR).

ADR-D · Coste por norma, no por factura; escalar por límites medidos

Problema. El coste y el rendimiento tienen que aguantar desde 500 facturas hasta una empresa real.

Decisión. Gastar tokens cuando cambia la norma, nunca por factura. Desplegar un servidor pequeño con el LLM remoto, y dar un paso de escalado sólo cuando salta un disparador leído de nuestros spans.


Opción	Por qué no / coste
Una llamada LLM por factura	Coste y latencia crecen con el volumen
Kubernetes y microservicios desde el primer día	Coste de operación sin una necesidad medida
Un LLM local siempre	Una GPU para un modelo que se usa minutos por norma; un modelo de 8B no logró compilar (medido)
Tokens por norma, un servidor, disparadores medidos (elegida)	Techo conocido de unas 8.000 facturas por proceso hasta el paso H1

Por qué (medido salvo lo marcado).

- tokens/mes = cambios de norma × 150k + escaladas consultadas × 3,7k; las facturas suman 0. 10.000 facturas y 2 normas al mes: unos 2,6M tokens (estimado).
- Motor: 500 facturas en 0,8 s. Techo: 8.000 por proceso, donde la regla de pedido duplicado tarda 9,4 s de su límite de 10 s. El arreglo, simulado: 50.000 en 31 s.
- El cuello de botella es el OCR: 1,2 s por escaneo frente a 25 ms por PDF con texto, pico de 2,6 GB.
- Una VM cuesta unos 10 € al mes (estimado); las personas son el 76 % del coste mensual.

Plan. Cuatro escenarios: una VM, infraestructura propia, nube gestionada y aislado con LLM local. Pasos horizontales H1-H10, cada uno con su disparador (población ≥ 3.000: indexar others; cola de OCR ≥ 100: workers de OCR). Vertical: un tipo de archivo nuevo es un lector nuevo (factura XML, CSV, imágenes, email); motor y reglas no cambian.

Coste. Hasta que llegue H1, un proceso con más de unas 8.000 facturas lo escala todo (falla cerrado).



Detalle: ADR 0020, 0012; docs/scale-and-cost.md.

ADR-E · Cambiar sin código, recuperarse sin perder nada

Problema. La norma y los datos cambian en directo, el ERP falla a propósito y los proveedores LLM se caen.


Decisión. Un cambio de norma es configuración: texto nuevo, reglas recompiladas y una versión inmutable del proceso que el manager publica entera o no publica. La historia es *append-only*: un cambio se repite sobre las decisiones pasadas como alertas, nunca como ediciones. Ante un fallo, el siguiente modelo o el último snapshot bueno.

Opción	Por qué no / coste
Un cambio de código por versión de la norma	Cada cambio necesita al equipo
Activar cada regla en cuanto compila	Una compilación fallida deja la norma aplicada a medias
Reescribir decisiones pasadas tras un cambio	Se pierde qué se decidió y por qué
Configuración, versiones atómicas, historia <i>append-only</i> y reservas (elegida)	La historia crece sin límite; el manager tiene que publicar y atender alertas

Por qué (medido, docs/resilience.md).

- Todos los LLM caídos: 500 facturas subidas, decididas y exportadas, referencia 471/471, 0 tokens. Con el modelo principal caído respondió glm5.3 .
- Una regla nueva que no compiló quedó en `draft` y no se puede publicar: 500 decisiones sin cambios. Recompilada y publicada: 38 alertas de decisiones obsoletas en 1,1 s.
- `kill -9` tras 68 de 500 subidas: la repetición acabó con 500 instancias, sin duplicados. Una copia restaurada coincide en el md5 de las 503 decisiones.
- ERP caído: la sync se rindió a los 11 s y siguió vigente el snapshot anterior.

Coste. Una norma nueva espera a que el manager la publique, y los datos del ERP pueden tener minutos.



Detalle: ADR 0007, 0008, 0011, 0013, 0015, 0019, 0022 (versiones), 0023, 0024, 0026; docs/resilience.md .